关注公众号 ok-shuxue，免费领取更多资料

R030 超几何分布的期望公式

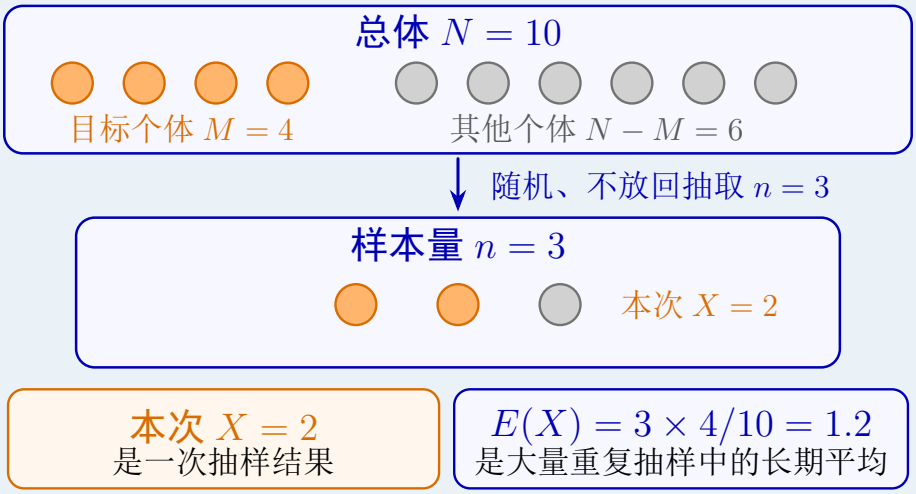
二级结论

结论主题

超几何分布研究：从有限总体中等可能地、不放回抽样，并统计样本中的目标个体数。

一般模型

总体共有 N 个个体，其中 M 个为目标个体；不放回抽取 n 个，令 X 为样本中的目标个体数。要求 $N \in \mathbb{N}^+$，$M, n \in \mathbb{N}$，$0 \le M, n \le N$，且每个 n 元子集被抽中的概率相同。



图中的重复抽样，是每一轮都从相同组成的总体重新开始。

核心结论 若记总体目标比例为 $p = M/N$，则

$$\boxed{E(X) = \frac{nM}{N} = np.}$$

也就是：**样本中目标个体数的期望 = 样本量 × 总体目标比例。**

取值范围与边界

$$\max\{0, n - (N - M)\} \le X \le \min\{M, n\}, \qquad X \in \mathbb{Z}.$$

公式包含 $n = 0$、$M = 0$、$M = N$ 和 $n = N$ 等退化情形；上下界的来源将在第 6 页用两个极端样本解释。

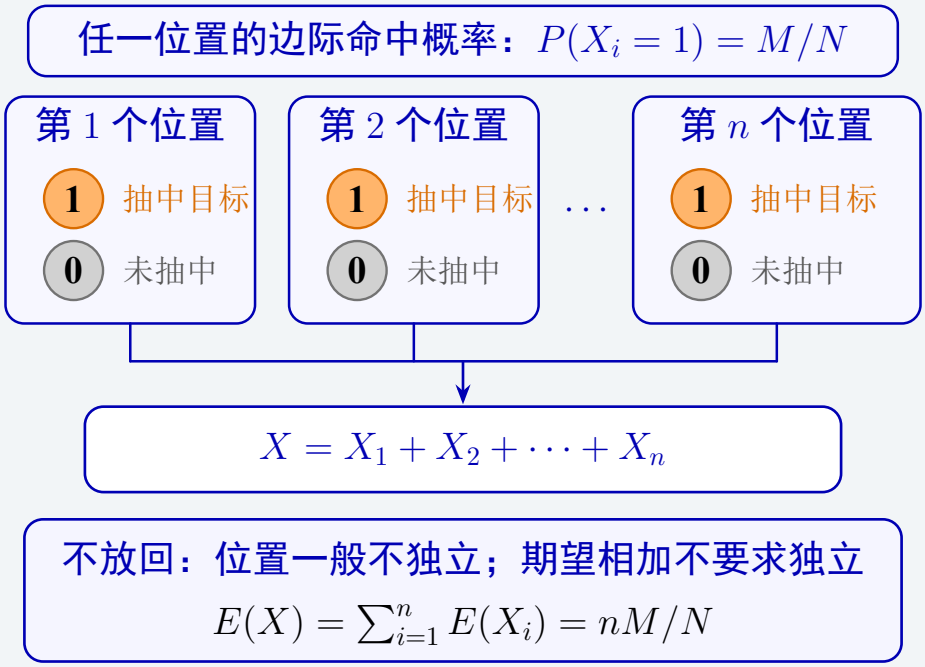
© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

理解说明

一句话直觉

把每个抽取位置看成一个只会贡献 0 或 1 的计数器；把 n 个位置的贡献相加，就得到样本中的目标个体总数 X。



读图关键

- M/N 是任一固定位置命中目标个体的**边际概率**，不是在已知前面抽取结果后的条件概率。
- 不放回会使位置之间一般不独立，但期望的线性性质对相关的随机变量同样成立，因此仍可逐项相加。

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

证明

证明一：指示变量法

把无放回抽样想成依次产生 n 个抽取位置。对 $i=1,2,\dots,n$，定义

$$X_i=\begin{cases}1, & \text{第 } i \text{ 个位置抽中目标个体},\\ 0, & \text{第 } i \text{ 个位置未抽中目标个体}.\end{cases}$$

于是目标个体总数为

$$X=X_1+X_2+\cdots+X_n.$$

固定任意一个位置 i。因为 N 个个体出现在第 i 个位置的机会相同，而其中有 M 个目标个体，所以

$$P(X_i=1)=\frac{M}{N},\qquad E(X_i)=1\cdot\frac{M}{N}+0\cdot\left(1-\frac{M}{N}\right)=\frac{M}{N}.$$

这里没有把 $X_1,\dots,X_n$ 当作相互独立；只使用了每个位置的边际概率。

由期望的线性性质，

$$\begin{aligned}E(X)&=E(X_1+X_2+\cdots+X_n)\\&=E(X_1)+E(X_2)+\cdots+E(X_n)\\&=n\cdot\frac{M}{N}=\frac{nM}{N}.\end{aligned}$$

这就证明了核心结论；$n=0$、$M=0$ 等退化情形也由同一公式直接得到。

证明二：用分布列复核

当 $1\le n\le N$ 且 $1\le M\le N$ 时，对所有合法整数 k，

$$P(X=k)=\frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}.$$

利用恒等式 $k\binom{M}{k}=M\binom{M-1}{k-1}$ 和范德蒙德恒等式，得到

$$\begin{aligned}E(X)&=\frac{1}{\binom{N}{n}}\sum_k k\binom{M}{k}\binom{N-M}{n-k}\\&=\frac{M}{\binom{N}{n}}\sum_k\binom{M-1}{k-1}\binom{N-M}{n-k}\\&=\frac{M\binom{N-1}{n-1}}{\binom{N}{n}}=\frac{nM}{N}.\end{aligned}$$

求和中的 k 遍历 $\max\{0,n-(N-M)\}\le k\le\min\{M,n\}$；超出范围的组合数不参与求和。两个证明相互印证。

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

典型例题

例 3（期望相同，分布未必相同）

题目： 总体有 $N=10$ 个个体，其中 $M=4$ 个为目标个体。若不放回抽取全部 $n=10$ 个，目标个体数记为 X；若每次放回并独立抽取 10 次，命中次数记为 Y。比较两者。

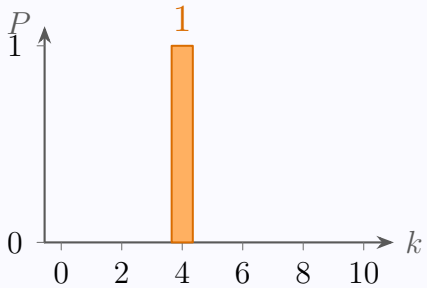
计算：

$$E(X)=\frac{10\times 4}{10}=4,\qquad E(Y)=10\times 0.4=4.$$

期望相同 $\neq$ 分布相同

不放回抽完总体

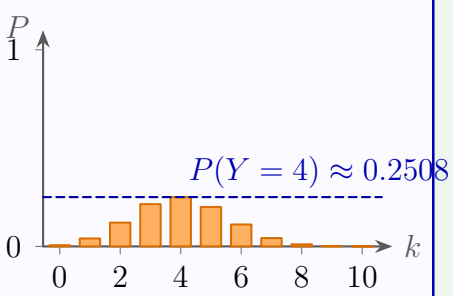
$X\equiv 4,\quad E(X)=4$



仅 $X=4$：完全不波动

有放回独立抽取 10 次

$Y\sim B(10,0.4),\quad E(Y)=4$



0 至 10 均可能，4 附近较大

答案与回验： 两者期望都为 4；但 $X\equiv 4$，而 $Y\sim B(10,0.4)$ 会在 0 至 10 间波动，所以二者不同分布。柱高由二项分布公式逐项计算，概率和为 1，加权均值为 4。

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

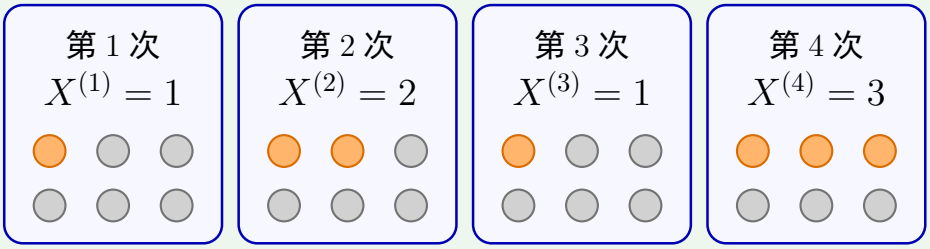
典型例题

例 1（直接应用与非整数期望）

一批零件共有 24 件，其中 7 件带有标记。从中等可能地、不放回抽取 6 件，记带标记零件数为 X。则

$$E(X)=\frac{nM}{N}=\frac{6\times 7}{24}=\frac{7}{4}=1.75.$$

四次完整抽样的示意结果（每次样本量 $n=6$）



$$(1+2+1+3)/4=7/4=1.75$$

每一次抽到的件数都是整数

但多次整数结果的平均值可以是小数

说明：这只是一组帮助理解的示意结果，不表示每 4 次抽样的平均值必然是 1.75。

答案与回验： 1.75 是大量同类抽样中目标个体数的长期平均，不是某一次抽样会出现的件数；且它位于 X 的最小可能值与最大可能值之间。

典型例题

例 2（由期望反求总体参数）

总体共有 60 个个体，其中 M 个为目标个体；无放回抽取 15 个，目标个体数为 X。若 $E(X)=3$，则

$$3=\frac{15M}{60}=\frac{M}{4},\qquad M=12.$$

代回得 $15\times(12/60)=3$，且 $M=12$ 是满足 $0\le M\le 60$ 的整数，因此答案成立。

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

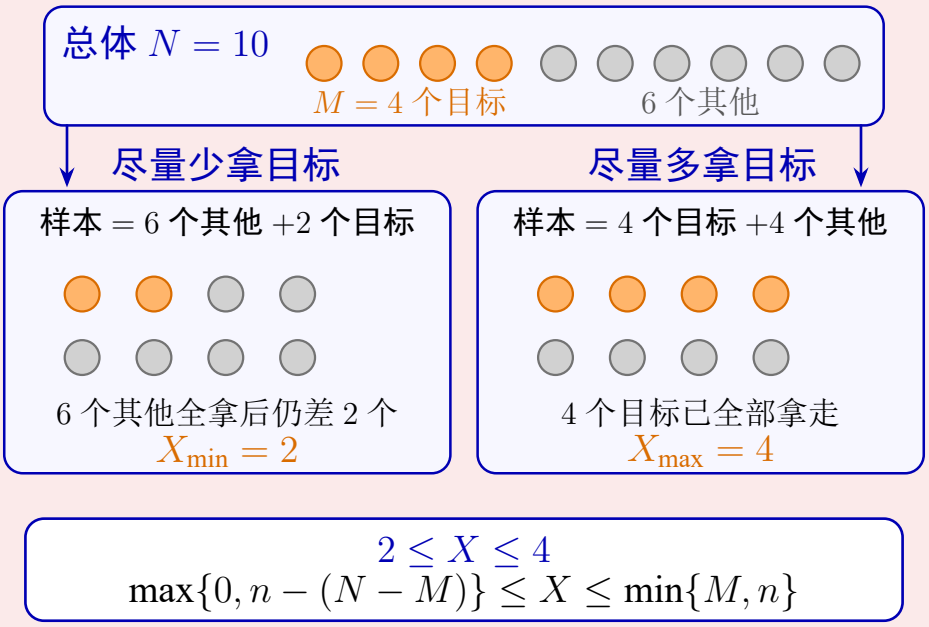
关注公众号 ok-shuxue，免费领取更多资料

易错提醒

易错点一：只抄取值范围，不理解极端情形

错误做法：机械写出 max、min 公式，却说不清下界为什么可能大于 0、上界为什么同时受 M 与 n 限制。

错误原因：忽略了“其他个体不够用”和“目标个体、样本位置都有限”这两个容量约束。



正确替代：先分别构造“尽量少拿目标”和“尽量多拿目标”的样本，再写一般上下界；同时检查 N,M,n 都是满足 $0\le M,n\le N$ 的计数参数。

易错点二：把总体比例当成计数期望

错误做法：写成 $E(X)=M/N$。　**错误原因：**M/N 只是一个位置的命中概率，X 统计 n 个位置的命中总数。　**正确替代：**先写 $p=M/N$，再用 $E(X)=np=nM/N$。

易错点三：由 $E(X)=np$ 断言 $X\sim B(n,p)$

错误做法：把不放回抽样直接套成二项分布。　**错误原因：**各位置一般不独立；期望相同不能推出分布相同。　**正确替代：**求期望可用 np，求具体概率仍应使用超几何分布列。

易错点四：把非整数期望当成一次抽样结果

错误做法：由 $E(X)=1.75$ 断言“一次会抽到 1.75 个”。　**错误原因：**期望是概率加权平均，不必属于 X 的取值集合。　**正确替代：**把 1.75 解释为大量同类抽样的长期平均，并用第 5 页的整数结果平均图检查直觉。

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

结论小结

一句话核心

有限总体中有 M 个目标个体，等可能地无放回抽取 n 个，则样本内目标个体数 X 的期望为 $E(X)=nM/N$。

速查关系

$$p=\frac{M}{N},\qquad E(X)=np=\frac{nM}{N},$$

$$\max\{0,n-(N-M)\}\le X\le \min\{M,n\}.$$

六个问题速答

1. N 是总体量，M 是总体目标数，n 是样本量，X 是样本内目标数。
2. 每个位置贡献 0 或 1，且 $E(X_i)=M/N$，所以 $E(X)=\sum E(X_i)=nM/N$。
3. 不放回使位置一般不独立，但期望相加不要求独立。
4. 非整数期望是多次整数结果的长期平均，不是一次抽样的可取件数。
5. 期望相同只说明分布的“平均位置”相同，不说明随机波动相同。
6. 下界来自“其他个体是否够用”，上界来自“目标总数与样本位置谁更少”。

解题流程

1. **识别：**有限总体、等可能、不放回、统计目标个体数。
2. **代入：**读出 N,M,n，使用 $E(X)=nM/N$。
3. **回验：**检查参数整数性、取值范围以及期望的长期平均含义。

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料