关注公众号 ok-shuxue，免费领取更多资料

R033 描述统计量：平均数、方差、中位数、众数

二级结论

对象与约定

给定 n 个实数 $x_1, x_2, \dots, x_n$，其中 $n \in \mathbb{N}^*$。将它们从小到大排列为 $x_{(1)} \le x_{(2)} \le \cdots \le x_{(n)}$。本结论中的“方差”采用高中描述统计口径，分母为 n；推断统计中分母为 $n-1$ 的无偏样本方差不在此处讨论。

集中趋势

平均数

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

它使用每一个数据值，表示这组数据的平衡水平。

中位数

$$\mathrm{Med} = \begin{cases} x_{((n+1)/2)}, & n \text{ 为奇数}, \\ \dfrac{x_{(n/2)} + x_{(n/2+1)}}{2}, & n \text{ 为偶数}. \end{cases}$$

它只由排序后的中间位置决定。

众数　出现次数达到最大值的数据。众数可能不唯一；若所有数据互不相同，高中统计中通常称“没有众数”。

离散程度

$$s^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2, \qquad s = \sqrt{s^2}.$$

恒有 $s^2 \ge 0$；并且

$$s^2 = 0 \iff x_1 = x_2 = \cdots = x_n.$$

方差的量纲是原数据量纲的平方，标准差与原数据同量纲。用方差或标准差比较波动时，两组数据应描述同一变量并采用相同单位。

频数表形式

若不同取值 $a_1, \dots, a_k$ 的频数分别为非负整数 $f_1, \dots, f_k$，总频数 $F = \sum_{j=1}^{k} f_j > 0$，则

$$\bar{x} = \frac{\sum_{j=1}^{k} f_j a_j}{F}, \qquad s^2 = \frac{\sum_{j=1}^{k} f_j (a_j - \bar{x})^2}{F}.$$

这不是另一套定义：它只是把每个 a_j 按频数 f_j 重复写出的简记。

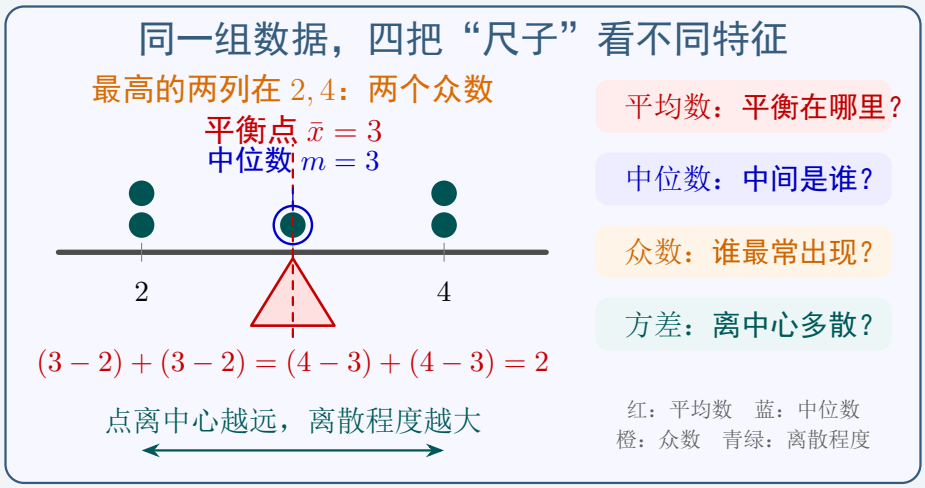
© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

理解说明

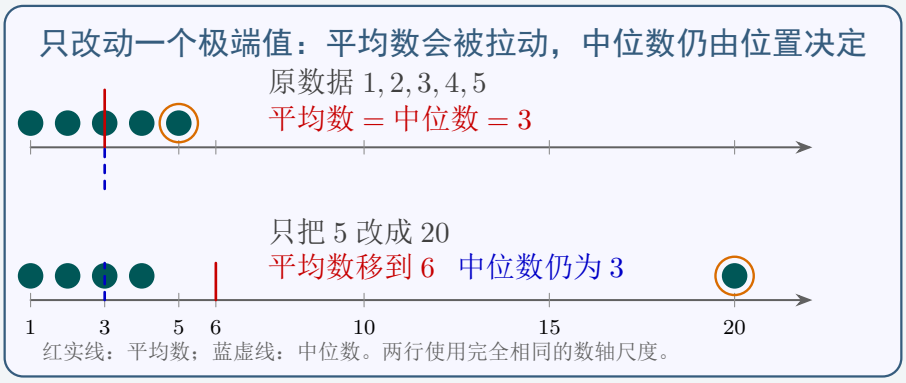
一句话直觉

平均数、中位数、众数分别看“平衡位置、中间位置、最高频位置”，方差与标准差则看数据离中心有多散。



图中同一组数据的平均数与中位数恰好都为 3，但含义不同；众数为 2 和 4，说明众数还可能不唯一。做题时先问“要描述哪一种特征”，再选统计量。

为什么极端值更容易拉动平均数



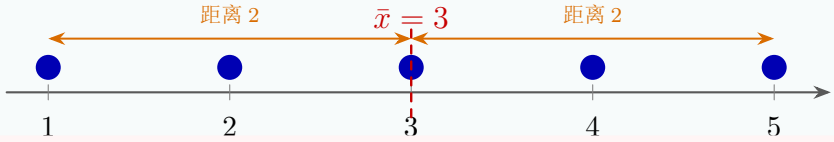
把 5 改成 20 后，总和增加 15，所以平均数增加 $15/5=3$；排序后的第 3 个数没有改变，中位数仍为 3。更准确地说，中位数对极端值**较稳健**：只要改动没有改变中间位置上的数据，它就不变；不能笼统说中位数永远不受数据改动影响。

方差为什么要“平方后再平均”

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

平方不只防止正负抵消，还会放大远处数据的影响



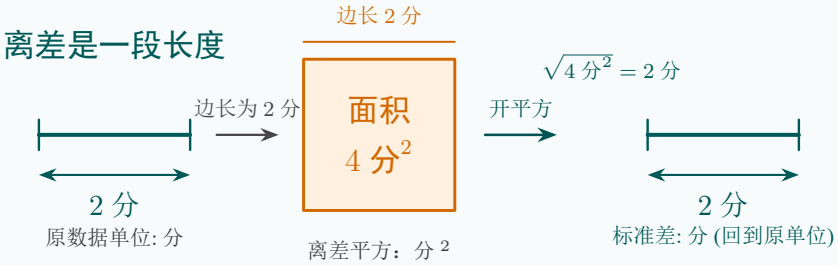
带符号离差	-2	-1	0	$+1$	$+2$	总和 $=0$，抵消后看不出分散
绝对距离	2	1	0	1	2	不会抵消，但对远点的放大较弱
平方距离	4	1	0	1	4	全部非负，远点得到更大权重

距离扩大 2 倍 $\Longrightarrow$ 平方距离扩大 4 倍

$$s^2=\frac{4+1+0+1+4}{5}=2$$

三行对照表明：平方既避免正负抵消，又比绝对距离更强调远离均值的数据；把平方距离除以数据个数，就得到方差。

平方把“长度”变成“面积”；开平方再回到长度



© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

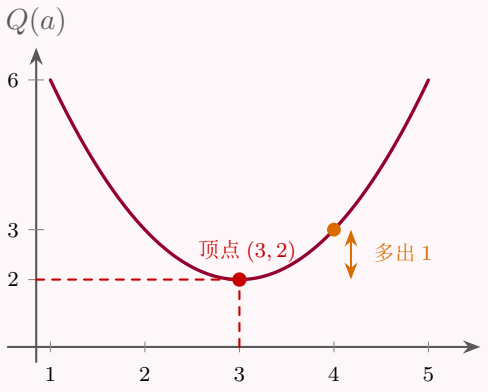
关注公众号 ok-shuxue，免费领取更多资料

证明

一、平均数为何是平方距离的唯一最小点

对数据 $1,2,3,4,5$，把候选中心记作 a，平均平方距离是 $Q(a)=2+(a-3)^2$：

候选中心偏离平均数多少，
平均平方距离就多出多少平方



数据 $1,2,3,4,5$，$\bar{x}=3$

$$Q(a)=\frac{1}{5}\sum_{i=1}^{5}(x_i-a)^2$$
$$=2+(a-3)^2$$

$a=\bar{x}=3$ 时，
唯一最小值为 $s^2=2$

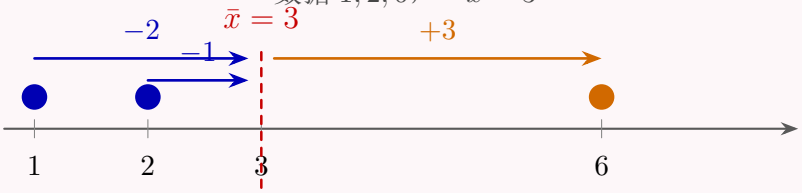
$a\neq 3\Rightarrow (a-\bar{x})^2>0$
不可能取得同一最小值

任取实数 a。由平均数定义，

$$\sum_{i=1}^{n}(x_i-\bar{x})=\sum_{i=1}^{n}x_i-n\bar{x}=0.$$

不必对称：平均数让所有带符号离差恰好平衡

数据 $1,2,6$，　$\bar{x}=3$



$$(-2)+(-1)+3=0$$
$$2(\bar{x}-a)\sum_{i=1}^{n}(x_i-\bar{x})=0$$

图中 $1,2,6$ 并不关于 3 对称，但 $-2+(-1)+3=0$；因此交叉项中的带符号离差和仍为零。于是

$$\begin{aligned}\frac{1}{n}\sum_{i=1}^{n}(x_i-a)^2&=\frac{1}{n}\sum_{i=1}^{n}\big[(x_i-\bar{x})+(\bar{x}-a)\big]^2\\&=\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2+\frac{2(\bar{x}-a)}{n}\sum_{i=1}^{n}(x_i-\bar{x})+(\bar{x}-a)^2\\&=s^2+(a-\bar{x})^2\geq s^2.\end{aligned}$$

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

等号成立当且仅当 $a=\bar{x}$。因此，平均数确实是使离差平方和最小的唯一位置。

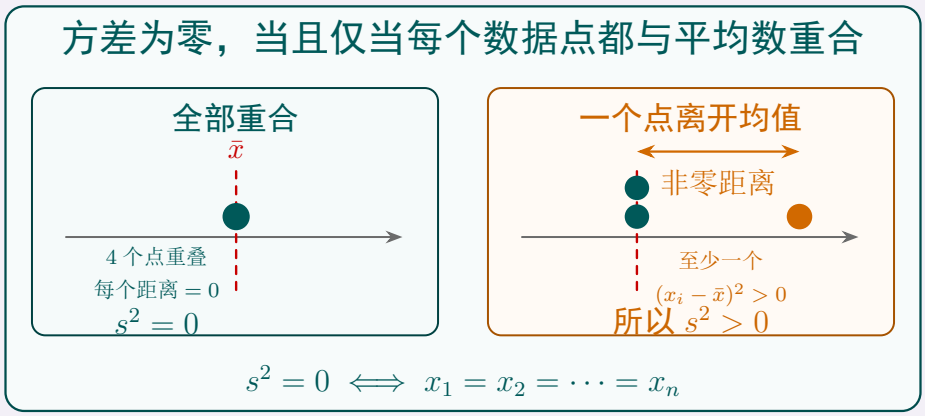
二、方差等价公式

从定义展开平方，并使用 $\sum_{i=1}^{n} x_i = n\bar{x}$：

$$\begin{aligned} s^2 &= \frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2 \\ &= \frac{1}{n}\left(\sum_{i=1}^{n}x_i^2 - 2\bar{x}\sum_{i=1}^{n}x_i + n\bar{x}^2\right) \\ &= \frac{1}{n}\sum_{i=1}^{n}x_i^2 - 2\bar{x}^2 + \bar{x}^2 \\ &= \frac{1}{n}\sum_{i=1}^{n}x_i^2 - \bar{x}^2. \end{aligned}$$

频数表只是在每个取值前加入重复次数 f_j；将每项乘以 f_j、把 n 换成 $F=\sum f_j$，同样的推导仍成立。

三、零方差的等号条件



因为每一项 $(x_i-\bar{x})^2 \geq 0$，这些非负数的平均为 0，当且仅当每一项都为 0。因此

$$s^2 = 0 \iff x_1 = x_2 = \cdots = x_n = \bar{x}.$$

典型例题

例 1：一次求全五个统计量

给定数据 $2,2,3,4,4$，求平均数、中位数、众数、方差和标准差。

数据已经有序，$n=5$，所以中位数是第 3 个数，即 3；2 与 4 都出现 2 次，故它们都是众数。又

$$\bar{x} = \frac{2+2+3+4+4}{5} = 3,$$

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

$$s^2 = \frac{(2-3)^2+(2-3)^2+(3-3)^2+(4-3)^2+(4-3)^2}{5}$$
$$= \frac{4}{5} = 0.8, \qquad s = \sqrt{\frac{4}{5}} = \frac{2\sqrt{5}}{5} \approx 0.894.$$

用等价公式回验：

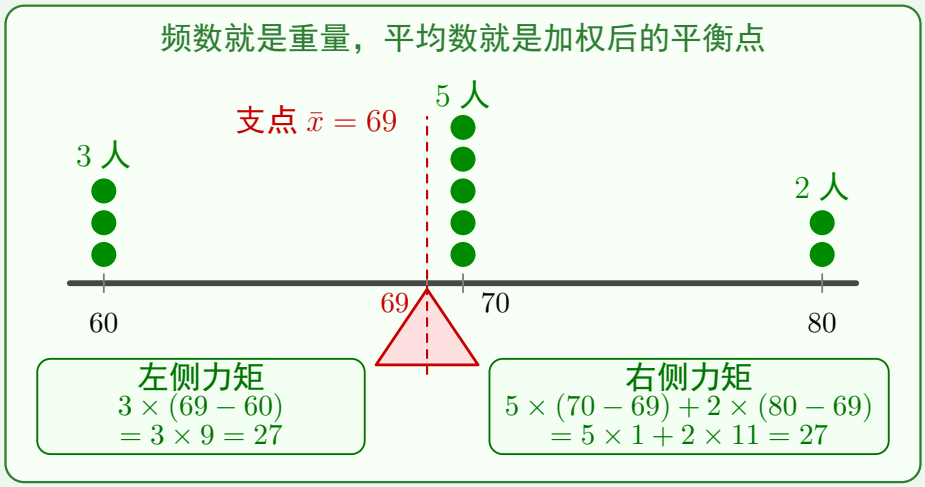
$$\frac{2^2+2^2+3^2+4^2+4^2}{5} - 3^2 = \frac{49}{5} - 9 = \frac{4}{5},$$

与定义式一致。

例 2：从频数表计算

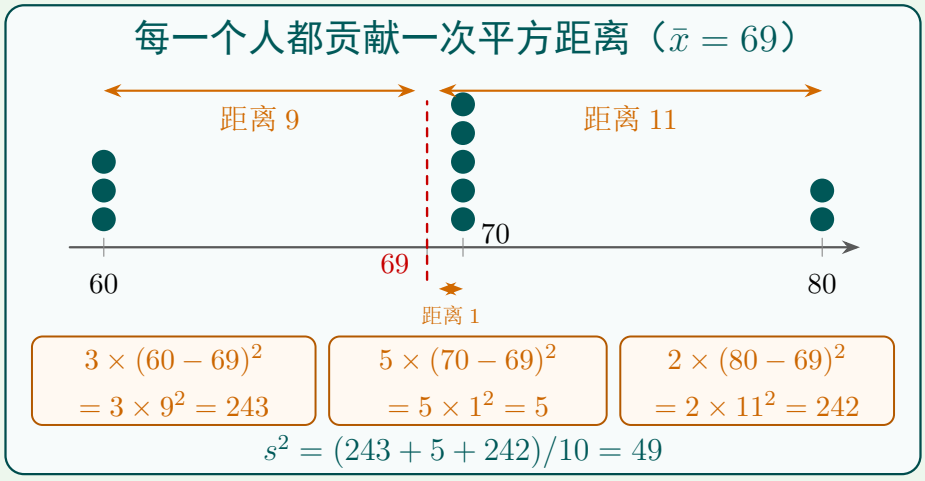
某次测验中，60 分有 3 人，70 分有 5 人，80 分有 2 人。总人数 $F = 10$，故

$$\bar{x} = \frac{3\times 60 + 5\times 70 + 2\times 80}{10} = 69.$$



频数必须同时进入方差的分子：

$$s^2 = \frac{3(60-69)^2+5(70-69)^2+2(80-69)^2}{10}$$
$$= \frac{243+5+242}{10} = 49, \qquad s = 7 \text{ 分}.$$



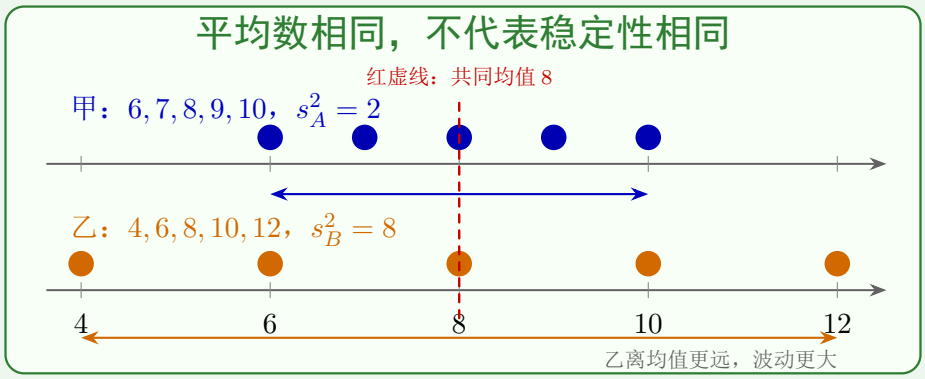
© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

例 3：平均水平相同，谁更稳定

甲、乙五次成绩分别为

$$A: 6,7,8,9,10, \qquad B: 4,6,8,10,12.$$



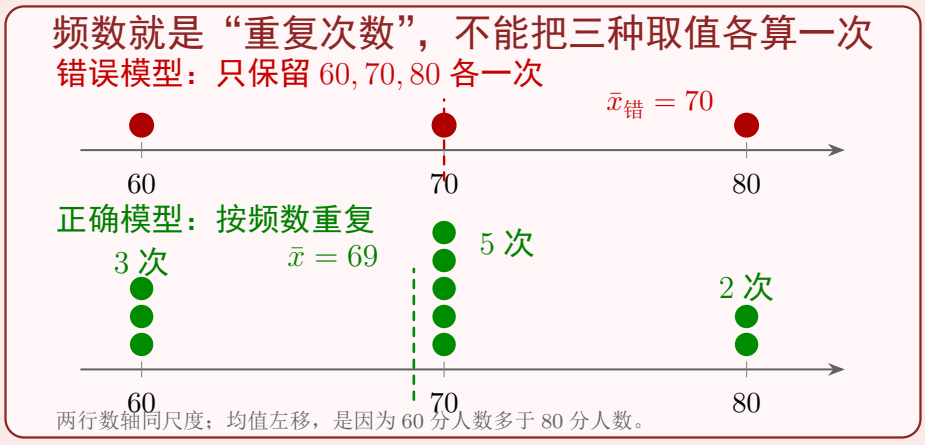
两组总和都为 40，所以 $\bar{x}_A = \bar{x}_B = 8$。但

$$s_A^2 = \frac{4+1+0+1+4}{5} = 2, \qquad s_B^2 = \frac{16+4+0+4+16}{5} = 8.$$

因此 $s_A = \sqrt{2} < s_B = 2\sqrt{2}$。两人的平均水平相同，但甲的数据更集中，成绩更稳定。图中两行采用同一尺度，结论也与数值计算一致。

易错提醒

误区一：频数表中把不同取值各算一次



错误：把 60, 70, 80 三种取值各算一次，得到错误平均数 70。

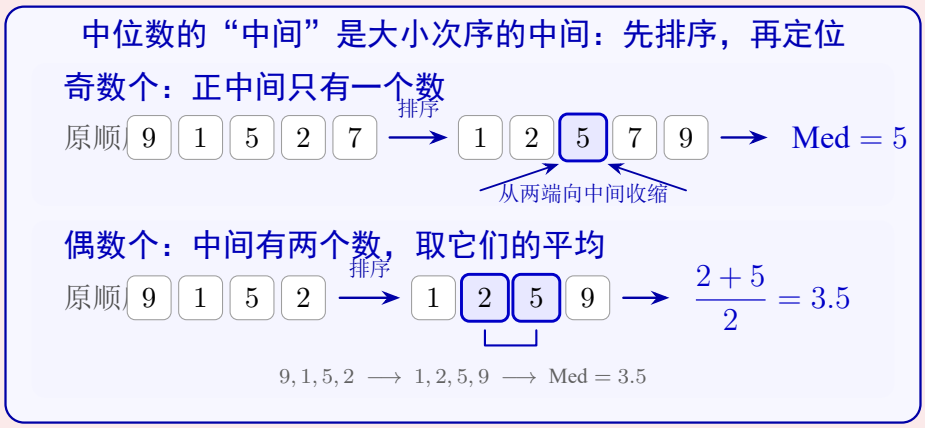
错因：这等于假设三种成绩各出现一次，丢掉了频数。

替代：按频数重复（或加权）可得 $\bar{x} = 69$；计算方差也须使用同一组频数。

误区二：不排序就取中间

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料



错误：在原书写顺序中直接取“中间”的数。

错因：中位数的“中间”是大小次序的中间，原书写位置没有统计意义。

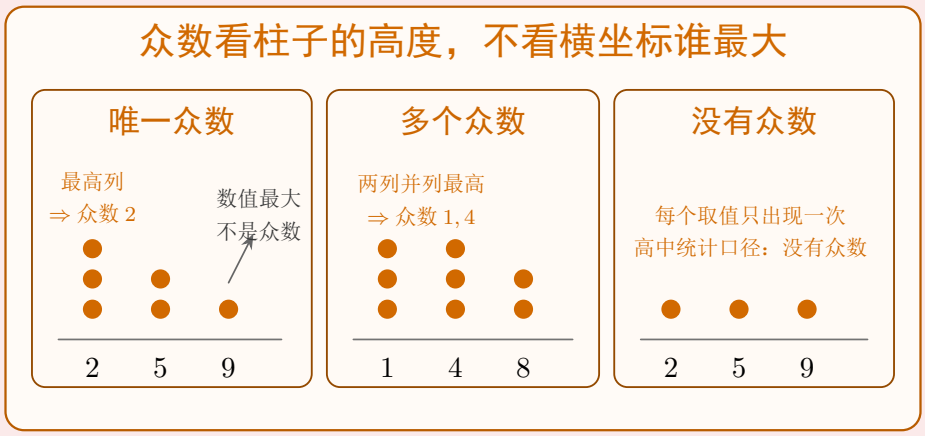
替代：先排序；奇数个取正中一项，偶数个取中间两项的平均。

误区三：把众数当成最大的数

错误：把最大值 9 当成众数。

错因：众数比较出现次数，不比较数值大小。

替代：2 出现两次，故众数为 2；最高频数并列时可以有多个众数。



误区四：混淆离差和、方差与标准差

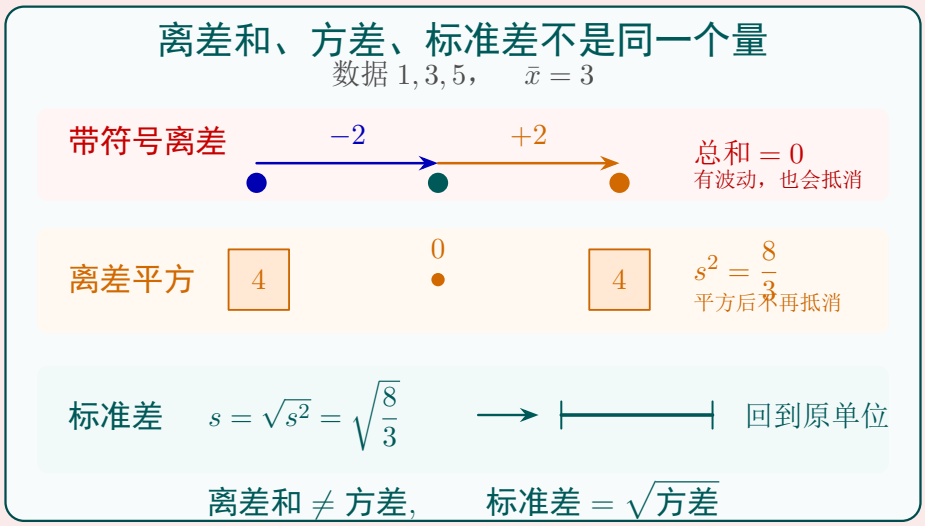
错误：由 $\sum(x_i - \bar{x}) = 0$ 断言方差为 0，或把 s^2 当成标准差。

错因：离差会正负抵消；方差平均的是离差平方，而且方差不等于标准差。

替代：先算 s^2；若题目问标准差，再取非负平方根 $s = \sqrt{s^2}$。

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

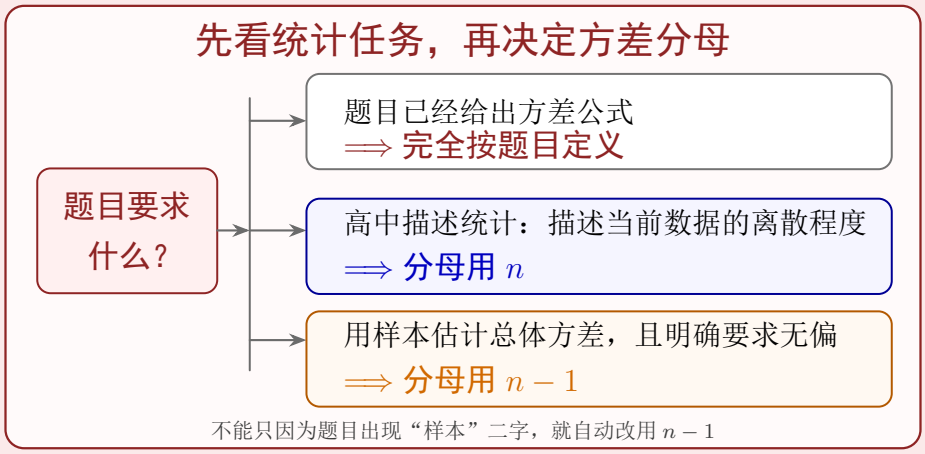


误区五：见到“样本”就机械除以 $n-1$

错误：见到“样本”就机械地把方差分母改为 $n-1$。

错因：分母取决于定义和任务语境；$n-1$ 是无偏样本方差的口径。

替代：本结论使用分母 n；若题目另给公式，则按题目定义。



© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料

结论小结

一句话核心

先分清要描述的是平衡位置、中间位置、最高频位置还是离散程度，再分别选平均数、中位数、众数或方差（标准差）。

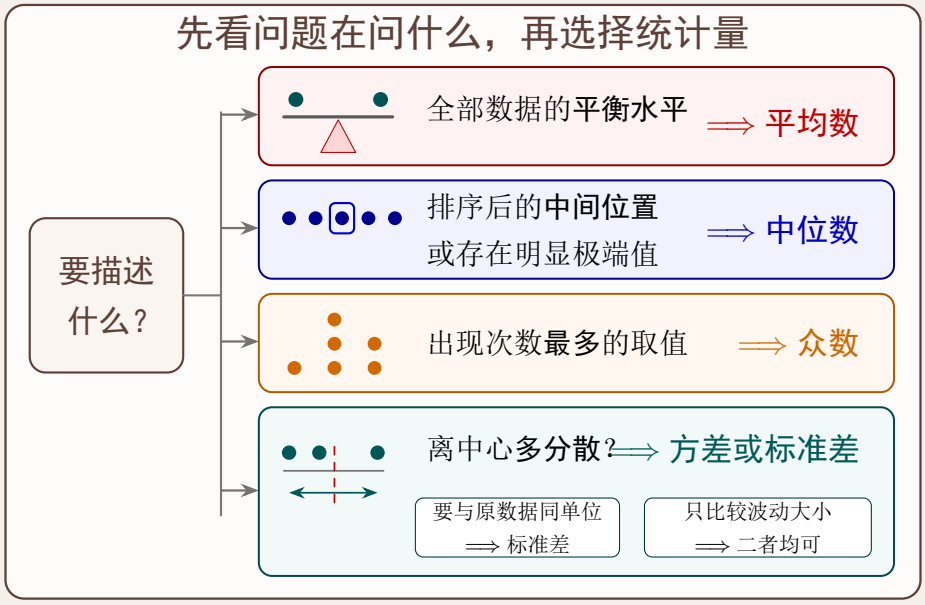
速查公式

$$\bar{x}=\frac{1}{n}\sum x_i,\qquad s^2=\frac{1}{n}\sum(x_i-\bar{x})^2=\frac{1}{n}\sum x_i^2-\bar{x}^2,\qquad s=\sqrt{s^2}.$$

频数表中令 $F=\sum f_j$：

$$\bar{x}=\frac{\sum f_j a_j}{F},\qquad s^2=\frac{\sum f_j(a_j-\bar{x})^2}{F}.$$

判断顺序



最后检查

- 中位数是否已经排序？偶数个数据是否取了中间两数的平均？
- 频数是否进入平均数和方差的分子，分母是否为总频数？
- 方差是否非负？$s^2=0$ 是否只在全部数据相同时出现？
- 题目问的是方差还是标准差？本题采用分母 n 还是题目另给定义？

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料