

线性回归的最小二乘估计公式

二级结论


代数上的唯一性条件 给定成对样本 (x_i, y_i) ($i = 1, \dots, n$)。只要

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 > 0, \quad \bar{x} = \frac{1}{n} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_i.$$

就存在唯一一条使纵向残差平方和最小的直线。

建模上的适用性检查 散点整体大致呈线性趋势时，用直线描述才比较合理；这不是计算公式的前提。即使散点明显弯曲，只要 $S_{xx} > 0$ ，仍可计算唯一的最小二乘直线，只是它可能遗漏原数据中的曲线结构。

先看散点：趋势近似线性且 x 必须有展开



最小二乘结论 在所有直线 $\hat{y} = a + bx$ 中，令纵向残差平方和

$$Q(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2 = \sum_{i=1}^n e_i^2$$

最小的直线为

$$\hat{b} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x}, \quad \hat{y} = \hat{a} + \hat{b}x.$$

这里 $e_i = y_i - \hat{y}_i$ 是沿 y 轴方向的残差。特别地，回归线恒过样本中心 $(\bar{x}, \bar{y})$ 。这里“唯一”指最优直线唯一；若 $S_{xx} = 0$ ，仍有最优直线，但斜率不能由数据唯一确定。

理解说明


先回答“为什么要过中心” 先固定斜率，把直线想成一把只能上下滑动的倾斜尺子。若残差和大于 0，数据点整体偏在线上方，尺子还应上移；若残差和小于 0，尺子整体偏高，应该下移。最平衡的位置满足

$$\sum_{i=1}^n (y_i - a - bx_i) = 0 \iff \bar{y} = a + b\bar{x}.$$

所以对固定的 b ，最佳截距使直线经过 $(\bar{x}, \bar{y})$ 。样本中心是整团数据的平衡点，不一定是某个原始数据点。

一句话直觉 先把直线限制为经过样本中心，再比较不同倾斜程度的纵向误差；误差平方和最小的那条就是回归线。


同一坐标尺度下比较：残差平方和最小的候选线最优




每条红线段均为纵向残差；只画三条候选线，严格全局最优见后文。

上图替代“反复试斜率、逐点计算”的长叙述：三个候选线都过 $(2.5, 4)$ ，但只有 $\hat{y} = 1.4x + 0.5$ 使 $Q = 0.20$ 最小。1.0 与 1.8 距最优斜率 1.4 都是 0.4，故它们的 Q 同为 1.00。图中只抽取三条候选线；严格的全局最优证明见后文。

最小二乘最小化纵向残差平方，不是点到直线的最短距离





为什么最小二乘选择平方？



读图关键 普通最小二乘解决“已知 x ，预测 y ”： x_i 已给定，不能左右移动，只比较真实 y_i 与预测 $\hat{y}_i$ 的上下差 $e_i = y_i - \hat{y}_i$ 。它不是点到直线的最短垂距 $d_{\perp} = |e_i|/\sqrt{1+b^2}$ ；候选斜率改变时，该分母也改变，因而是另一个优化问题。绝对值同样能避免抵消；选择平方还因为计算方便、函数光滑，并会更重地惩罚大误差。

样本中心固定位置；离差乘积和决定斜率方向



把中心移到原点后，每个样本点都在给斜率方向“投票”：右上、左下的离差乘积为正；左上、右下为负；离中心越远，矩形面积越大、权重越大。于是 $S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$ 是总体倾斜信号的带权代数和， $S_{xx} = \sum (x_i - \bar{x})^2$ 是 x 的横向展开程度；即“斜率 = 总体倾斜信号 ÷ 横向展开程度”。

证明

配方法证明（正文） 令

$$d = \bar{y} - a - b\bar{x}.$$

则

$$y_i - a - bx_i = [(y_i - \bar{y}) - b(x_i - \bar{x})] + d.$$

因为 $\sum(x_i - \bar{x}) = 0$ 、 $\sum(y_i - \bar{y}) = 0$ ，平方展开后的交叉项相消：

$$Q(a, b) = \sum [(y_i - \bar{y}) - b(x_i - \bar{x})]^2 + nd^2.$$

固定 b 时，第一项不随 a 改变，而 $nd^2 \geq 0$ ；故最优时 $d = 0$ ，即 $a = \bar{y} - b\bar{x}$ 。这也解释了回归线必过样本中心：总误差有一笔来自“直线在中心处太高或太低”，先把这笔降到 0。

代入后，记 $S_{yy} = \sum(y_i - \bar{y})^2$ ，得到

$$Q(b) = S_{yy} - 2bS_{xy} + b^2S_{xx} = S_{xx} \left(b - \frac{S_{xy}}{S_{xx}} \right)^2 + S_{yy} - \frac{S_{xy}^2}{S_{xx}}.$$

当 $S_{xx} > 0$ 时，平方项仅在 $b = S_{xy}/S_{xx}$ 时为 0，所以唯一取得最小值。故


$$\hat{b} = \frac{S_{xy}}{S_{xx}}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x}.$$

拓展阅读：偏导数版本 下图把同一结论用二元函数的观点表示。右图的横轴只标 c ，其中 $c = a + \bar{x}b$ ；在 (c, b) 坐标中，误差碗的等高线满足


$$Q - Q_{\min} = n(c - \bar{y})^2 + S_{xx}(b - \hat{b})^2.$$

拓展：两个偏导分别调截距与倾斜；误差碗只有一个最低点

对 a ：固定 b ，直线上下平移



$c = a + \bar{x}b$ 与 b 的误差碗



令 $e_i = y_i - a - bx_i$ 。由 $\partial Q / \partial a = 0$ 与 $\partial Q / \partial b = 0$ ，分别得

$$\sum_{i=1}^n e_i = 0, \quad \sum_{i=1}^n x_i e_i = 0.$$

第一式化为 $n\bar{y} - na - bnx = 0$ ，即 $a = \bar{y} - b\bar{x}$ 。把它代入第二式，或先将第二式减去 $\bar{x} \sum e_i = 0$ ，得到


$$\sum_{i=1}^n (x_i - \bar{x}) [(y_i - \bar{y}) - b(x_i - \bar{x})] = 0.$$

因而

$$b \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

由 $S_{xx} > 0$ 可除得 $b = \hat{b}$ ，再由 $a = \bar{y} - b\bar{x}$ 得 $a = \hat{a}$ 。

中心化：样本中心移到新原点，样本之间的相对位置不变



中心化后 $\sum x'_i = 0$, $\sum y'_i = 0$ ；橙色的样本中心准确移到 O ，它不是原始样本点。

中心化还给出常用等价式：

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n\bar{x}\bar{y}, \quad \sum (x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2.$$

将 $\hat{a} = \bar{y} - \hat{b}\bar{x}$ 改写为 $\bar{y} = \hat{a} + \hat{b}\bar{x}$ ，即回归线经过样本中心；因此在这条约束下改变斜率时，整条候选线才是绕样本中心旋转。


典型例题

例 1（完整数据） 已知 $(1, 2), (2, 3), (3, 5), (4, 6)$ ，求回归线。

$$\bar{x} = 2.5, \quad \bar{y} = 4, \quad S_{xy} = 3 + 0.5 + 0.5 + 3 = 7, \quad S_{xx} = 2.25 + 0.25 + 0.25 + 2.25 = 5.$$


所以 $\hat{b} = 7/5 = 1.4$, $\hat{a} = 4 - 1.4 \times 2.5 = 0.5$, 即 $\hat{y} = 1.4x + 0.5$ 。中心点检查：
 $1.4 \times 2.5 + 0.5 = 4$, 说明截距按 $\hat{a} = \bar{y} - \hat{b}\bar{x}$ 计算一致；它不能单独验证斜率。

例 1：回归线过样本中心，但不必穿过任何原始数据点



例 2（只给统计量） 已知 $n = 5, \sum x_i = 15, \sum y_i = 20, \sum x_i y_i = 70, \sum x_i^2 = 55$ 。不虚构原始散点，直接使用等价式。

例 2：统计量按“均值—离差和—回归系数”顺序计算




两条支路分别计算离差乘积和与 x 的离差平方和；再合并得到 $\hat{b}$ ，最后利用样本中心求出 $\hat{a}$ ；最后做中心点检查。

由图中链条得 $\hat{y} = x + 1$ ；中心点检查：在 $(\bar{x}, \bar{y}) = (3, 4)$ 处， $3 + 1 = 4$ 。

例 3（下降趋势与预测） 数据 $(6, 8), (7, 7), (8, 6), (9, 5), (10, 4)$ 。有 $\bar{x} = 8, \bar{y} = 6, S_{xy} = -10, S_{xx} = 10$ ，故

$$\hat{y} = -x + 14, \quad \hat{y}(7.5) = 6.5.$$


例 3：在样本范围内沿下降回归线读出预测值



因为 7.5 位于样本 x 范围 $[6, 10]$ 内，这次是内插；图中虚线给出预测读数。

易错提醒

易错对照：没有横向变化时斜率不唯一；两种回归不能互相倒过来



误区一：把 $S_{xx} = 0$ 说成“回归直线不存在”。当所有 $x_i = x_0$ 时，

$$Q(a, b) = \sum_{i=1}^n [y_i - (a + bx_0)]^2.$$

令 $c = a + bx_0$ ，则最优预测值为 $c = \bar{y}$ ；全部最优解恰为

$$a + bx_0 = \bar{y}, \quad a = \bar{y} - bx_0.$$

也就是说，任意选择 b ，再相应取 a ，都会得到相同的最小残差平方和。数据只确定直线经过 $(x_0, \bar{y})$ ，却无法确定它穿过这里时该倾斜多少；正确结论是斜率无法唯一估计，而不是“回归直线不存在”。

误区二：把最小二乘解释成最短垂距，或把两种回归互相倒过来。已知 x 预测 y 时，惩罚上下猜错；已知 y 预测 x 时，惩罚左右猜错。这是两个不同的问题，不能把一个公式直接倒过来。只有所有数据点都恰好落在同一条直线上时，两种回归才表示同一条几何直线。

图右的数据为 $(1, 1), (2, 2), (3, 2), (4, 4)$ ，中心为 $(2.5, 2.25)$ 。 y 对 x 的回归为 $\hat{y} = 0.9x$ ；反向模型则是 $\hat{x} = \frac{18}{19}y + \frac{7}{19} \approx 0.947y + 0.368$ 。后者若要画在横轴为 x 、纵轴为 y 的普通坐标图中，必须等价改写为 $y = \frac{19}{18}x - \frac{7}{18} \approx 1.056x - 0.389$ 。这个改写只为画出同一条几何直线，不能把它当成“由 x 预测 y ”的公式。

误区三：以为中心点检查能验证整条直线。代入 $(\bar{x}, \bar{y})$ 只能检查截距是否按 $\hat{a} = \bar{y} - \hat{b}\bar{x}$ 计算，不能单独验证斜率；因为任取一个错误斜率 b ，再令 $a = \bar{y} - b\bar{x}$ ，直线仍会过中心。若需完整验算，可检查 $\sum e_i \approx 0$ 、 $\sum x_i e_i \approx 0$ （小数四舍五入时为近似）。

结论小结

一句话核心 在 x 有变化且散点趋势大致线性时，选取使纵向残差平方和最小的直线。

速查公式

$$\hat{b} = \frac{S_{xy}}{S_{xx}}, \quad S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}), \quad S_{xx} = \sum (x_i - \bar{x})^2, \quad \hat{a} = \bar{y} - \hat{b}\bar{x}.$$

判断流程 先确认 x_i 不全相同（即 $S_{xx} > 0$ ）；再求 $\bar{x}, \bar{y}, S_{xy}, S_{xx}$ ；接着求 $\hat{b}, \hat{a}$ ；最后做中心点检查截距，必要时检查 $\sum e_i \approx 0$ 。

最后检查

- 残差是否写成 $y_i - \hat{y}_i$ ，而非点到直线的最短距离？
- 分母是否是 x 的离差平方和，并且严格大于 0？
- S_{xy} 的符号是否与散点总体升降趋势一致？这只是粗略合理性检查，不是严格证明。
- 是否把样本中心检查只用于截距，而没有误称它能单独验证斜率？
- 预测 x 是否在样本范围内；若在范围外，应说明属于外推？
- 是否还观察了散点的明显弯曲、分组或异常点？能算出回归线不代表线性模型一定合适。