关注公众号 ok-shuxue，免费领取更多资料



# R038 线性回归的最小二乘估计公式

## 二级结论

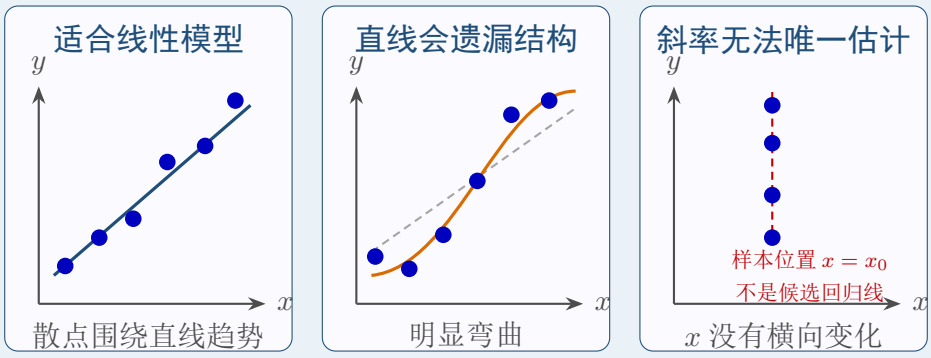
**代数上的唯一性条件** 给定成对样本 $(x_i, y_i)$ $(i = 1, \dots, n)$。只要

$$S_{xx} = \sum_{i=1}^{n}(x_i - \bar{x})^2 > 0, \qquad \bar{x} = \frac{1}{n}\sum x_i, \quad \bar{y} = \frac{1}{n}\sum y_i.$$

就存在唯一一条使纵向残差平方和最小的直线。

**建模上的适用性检查** 散点整体大致呈线性趋势时，用直线描述才比较合理；这不是计算公式的前提。即使散点明显弯曲，只要 $S_{xx} > 0$，仍可计算唯一的最小二乘直线，只是它可能遗漏原数据中的曲线结构。

### 先看散点：趋势近似线性且 $x$ 必须有展开




**最小二乘结论** 在所有直线 $\hat{y} = a + bx$ 中，令纵向残差平方和

$$Q(a, b) = \sum_{i=1}^{n}\big(y_i - a - bx_i\big)^2 = \sum_{i=1}^{n} e_i^2$$

最小的直线为

$$\boxed{\hat{b} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}}, \qquad \boxed{\hat{a} = \bar{y} - \hat{b}\bar{x}}, \qquad \hat{y} = \hat{a} + \hat{b}x.$$

这里 $e_i = y_i - \hat{y}_i$ 是沿 $y$ 轴方向的残差。特别地，回归线恒过样本中心 $(\bar{x}, \bar{y})$。这里“唯一”指最优直线唯一；若 $S_{xx} = 0$，仍有最优直线，但斜率不能由数据唯一确定。



© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料



## 理解说明

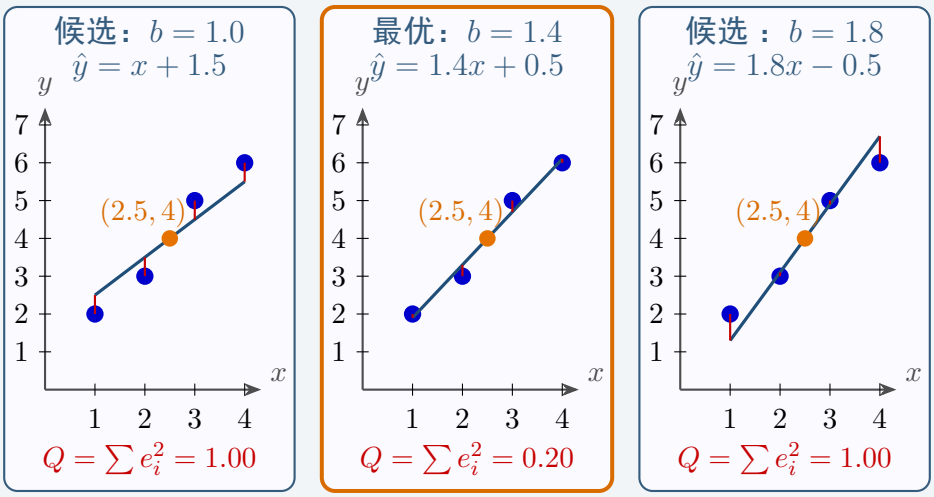
**先回答“为什么要过中心”**　先固定斜率，把直线想成一把只能上下滑动的倾斜尺子。若残差和大于 0，数据点整体偏在线上方，尺子还应上移；若残差和小于 0，尺子整体偏高，应该下移。最平衡的位置满足

$$\sum_{i=1}^{n}(y_i - a - bx_i) = 0 \quad \Longleftrightarrow \quad \bar{y} = a + b\bar{x}.$$

所以对固定的 $b$，最佳截距使直线经过 $(\bar{x}, \bar{y})$。样本中心是整团数据的平衡点，不一定是某个原始数据点。

**一句话直觉**　先把直线限制为经过样本中心，再比较不同倾斜程度的纵向误差；误差平方和最小的那条就是回归线。

### 同一坐标尺度下比较：残差平方和最小的候选线最优




每条红线段均为纵向残差；只画三条候选线，严格全局最优见后文。

上图替代“反复试斜率、逐点计算”的长叙述：三个候选线都过 $(2.5, 4)$，但只有 $\hat{y} = 1.4x + 0.5$ 使 $Q = 0.20$ 最小。1.0 与 1.8 距最优斜率 1.4 都是 0.4，故它们的 $Q$ 同为 1.00。图中只抽取三条候选线；严格的全局最优证明见后文。

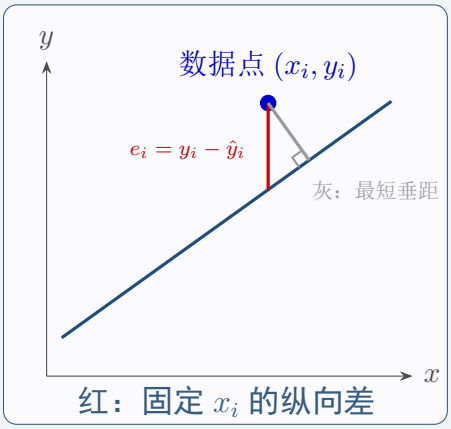


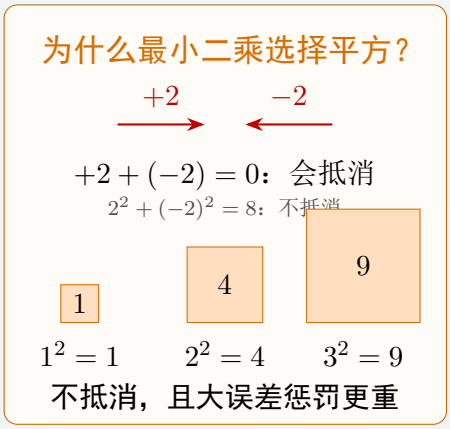
© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料



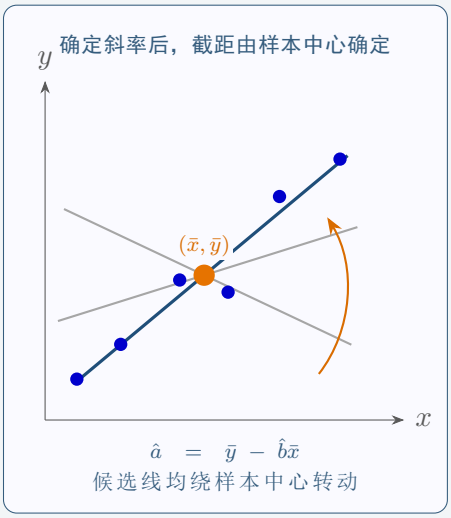
## 最小二乘最小化纵向残差平方，不是点到直线的最短距离

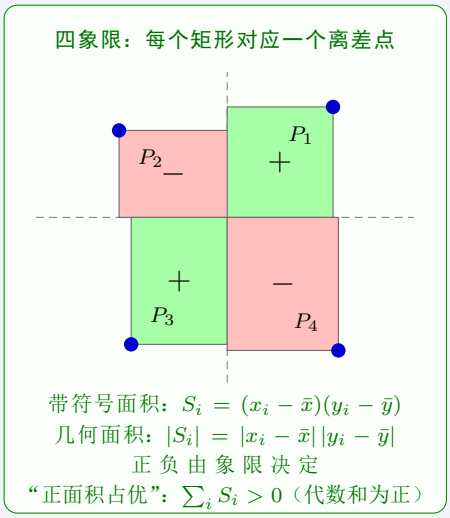



**读图关键**　普通最小二乘解决“已知 $x$，预测 $y$”：$x_i$ 已给定，不能左右移动，只比较真实 $y_i$ 与预测 $\hat{y}_i$ 的上下差 $e_i = y_i - \hat{y}_i$。它不是点到直线的最短垂距 $d_\perp = |e_i|/\sqrt{1+b^2}$；候选斜率改变时，该分母也改变，因而是另一个优化问题。绝对值同样能避免抵消；选择平方还因为计算方便、函数光滑，并会更重地惩罚大误差。

## 样本中心固定位置；离差乘积和决定斜率方向




把中心移到原点后，每个样本点都在给斜率方向“投票”：右上、左下的离差乘积为正；左上、右下为负；离中心越远，矩形面积越大、权重越大。于是 $S_{xy} = \sum(x_i - \bar{x})(y_i - \bar{y})$ 是总体倾斜信号的带权代数和，$S_{xx} = \sum(x_i - \bar{x})^2$ 是 $x$ 的横向展开程度；即“斜率 = 总体倾斜信号 ÷ 横向展开程度”。



© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料



**证明**

**配方法证明（正文）**　令

$$d=\bar{y}-a-b\bar{x}.$$

则

$$y_i-a-bx_i=\big[(y_i-\bar{y})-b(x_i-\bar{x})\big]+d.$$

因为 $\sum(x_i-\bar{x})=0$、$\sum(y_i-\bar{y})=0$，平方展开后的交叉项相消：

$$Q(a,b)=\sum\big[(y_i-\bar{y})-b(x_i-\bar{x})\big]^2+nd^2.$$

固定 $b$ 时，第一项不随 $a$ 改变，而 $nd^2\geq 0$；故最优时 $d=0$，即 $a=\bar{y}-b\bar{x}$。这也解释了回归线必过样本中心：总误差有一笔来自“直线在中心处太高或太低”，先把这笔降到 0。

代入后，记 $S_{yy}=\sum(y_i-\bar{y})^2$，得到

$$Q(b)=S_{yy}-2bS_{xy}+b^2S_{xx}=S_{xx}\left(b-\frac{S_{xy}}{S_{xx}}\right)^2+S_{yy}-\frac{S_{xy}^2}{S_{xx}}.$$

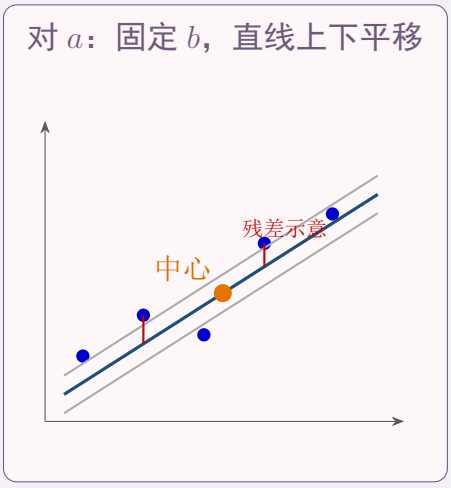
当 $S_{xx}>0$ 时，平方项仅在 $b=S_{xy}/S_{xx}$ 时为 0，所以唯一取得最小值。故

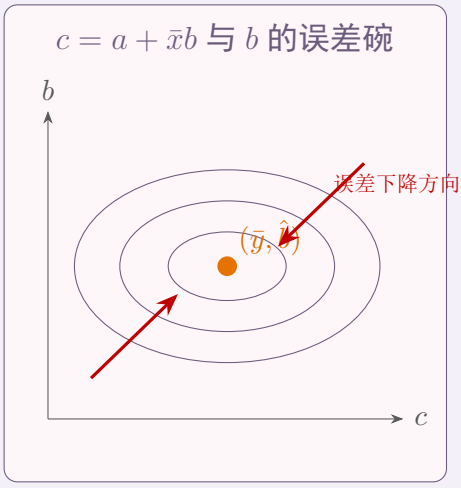
$$\hat{b}=\frac{S_{xy}}{S_{xx}},\qquad \hat{a}=\bar{y}-\hat{b}\bar{x}.$$

**拓展阅读：偏导数版本**　下图把同一结论用二元函数的观点表示。右图的横轴只标 $c$，其中 $c=a+\bar{x}b$；在 $(c,b)$ 坐标中，误差碗的等高线满足

$$Q-Q_{\min}=n(c-\bar{y})^2+S_{xx}(b-\hat{b})^2.$$

拓展：两个偏导分别调截距与倾斜；误差碗只有一个最低点






© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料



令 $e_i = y_i - a - bx_i$。由 $\partial Q/\partial a = 0$ 与 $\partial Q/\partial b = 0$，分别得

$$\sum_{i=1}^{n} e_i = 0, \qquad \sum_{i=1}^{n} x_i e_i = 0.$$

第一式化为 $n\bar{y} - na - bn\bar{x} = 0$，即 $a = \bar{y} - b\bar{x}$。把它代入第二式，或先将第二式减去 $\bar{x}\sum e_i = 0$，得到

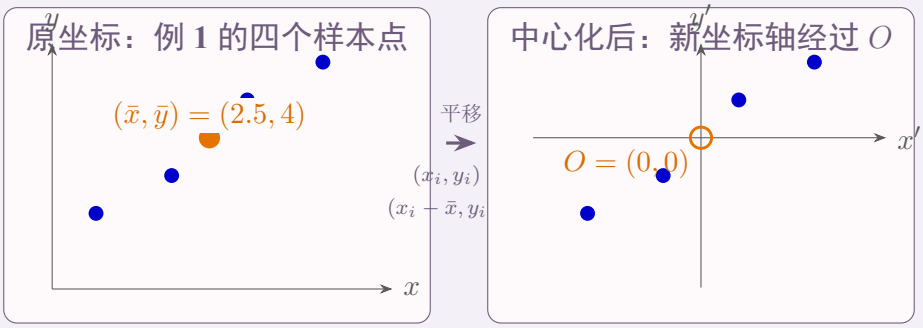
$$\sum_{i=1}^{n} (x_i - \bar{x})\big[(y_i - \bar{y}) - b(x_i - \bar{x})\big] = 0.$$

因而

$$b\sum_{i=1}^{n} (x_i - \bar{x})^2 = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}).$$

由 $S_{xx} > 0$ 可除得 $b = \hat{b}$，再由 $a = \bar{y} - b\bar{x}$ 得 $a = \hat{a}$。

### 中心化：样本中心移到新原点，样本之间的相对位置不变




中心化后 $\sum x_i' = 0$，$\sum y_i' = 0$；橙色的样本中心准确移到 $O$，它不是原始样本点。

中心化还给出常用等价式：

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n\bar{x}\bar{y}, \qquad \sum (x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2.$$

将 $\hat{a} = \bar{y} - \hat{b}\bar{x}$ 改写为 $\bar{y} = \hat{a} + \hat{b}\bar{x}$，即回归线经过样本中心；因此在这条约束下改变斜率时，整条候选线才是绕样本中心旋转。



© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料



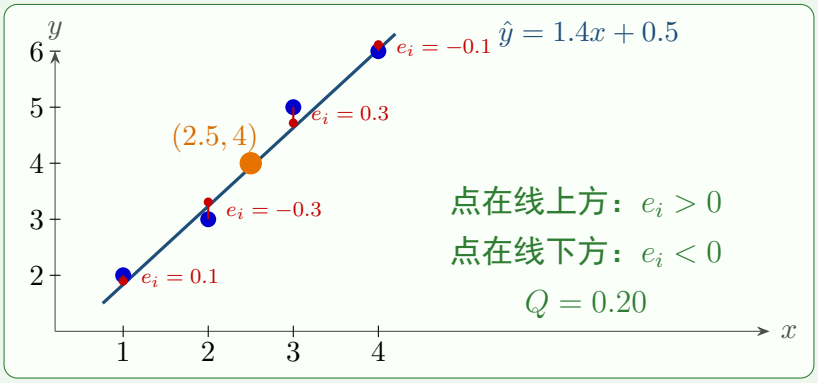
## 典型例题

**例 1（完整数据）**　已知 $(1,2),(2,3),(3,5),(4,6)$，求回归线。

$\bar{x}=2.5,\quad \bar{y}=4,\quad S_{xy}=3+0.5+0.5+3=7,\quad S_{xx}=2.25+0.25+0.25+2.25=5.$

所以 $\hat{b}=7/5=1.4$，$\hat{a}=4-1.4\times 2.5=0.5$，即 $\hat{y}=1.4x+0.5$。中心点检查：$1.4\times 2.5+0.5=4$，说明截距按 $\hat{a}=\bar{y}-\hat{b}\bar{x}$ 计算一致；它不能单独验证斜率。

**例 1：回归线过样本中心，但不必穿过任何原始数据点**





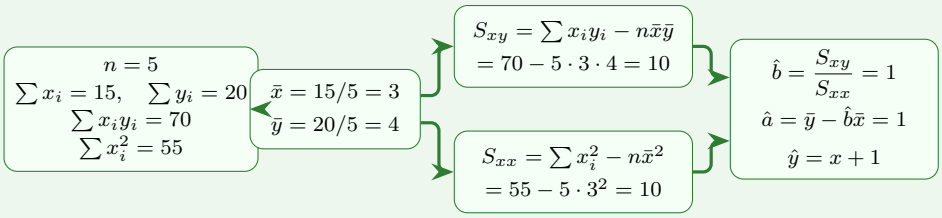

© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料



**例 2（只给统计量）**　已知 $n=5, \sum x_i=15, \sum y_i=20, \sum x_iy_i=70, \sum x_i^2=55$。不虚构原始散点，直接使用等价式。

### 例 2：统计量按“均值—离差和—回归系数”顺序计算



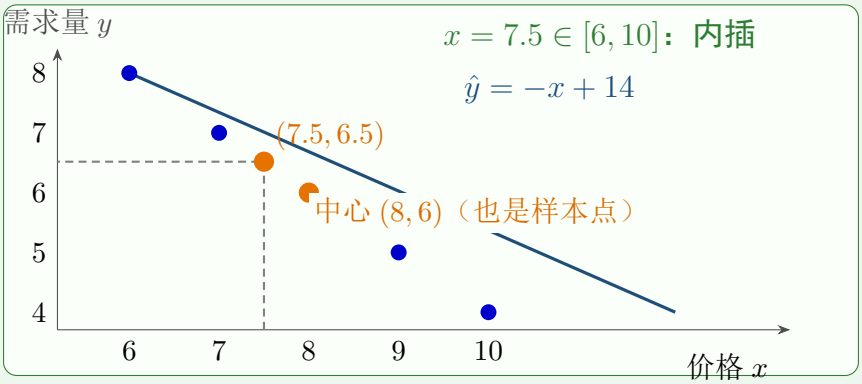

两条支路分别计算离差乘积和与 $x$ 的离差平方和；
再合并得到 $\hat{b}$，最后利用样本中心求出 $\hat{a}$；最后做中心点检查。

由图中链条得 $\hat{y}=x+1$；中心点检查：在 $(\bar{x},\bar{y})=(3,4)$ 处，$3+1=4$。

**例 3（下降趋势与预测）**　数据 $(6,8),(7,7),(8,6),(9,5),(10,4)$。有 $\bar{x}=8, \bar{y}=6, S_{xy}=-10, S_{xx}=10$，故

$$\hat{y}=-x+14, \qquad \hat{y}(7.5)=6.5.$$

### 例 3：在样本范围内沿下降回归线读出预测值




因为 7.5 位于样本 $x$ 范围 $[6,10]$ 内，这次是内插；图中虚线给出预测读数。



© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

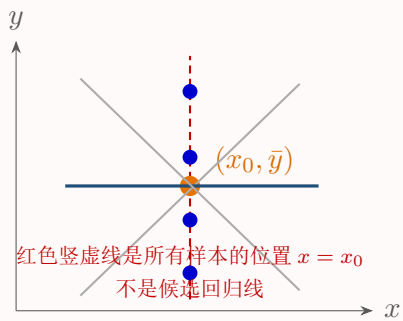
关注公众号 ok-shuxue，免费领取更多资料



## 易错提醒

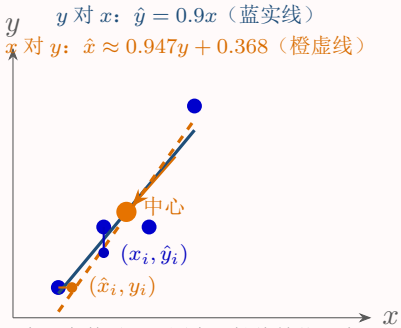
### 易错对照：没有横向变化时斜率不唯一；两种回归不能互相倒过来

$x = x_0$：斜率无法唯一估计




任意 $b$，取 $a = \bar{y} - bx_0$
都经过 $(x_0, \bar{y})$

同一数据的两种回归：优化方向不同




为画在普通 $x$-$y$ 图中，橙线等价写为
$y = \frac{19}{18}x - \frac{7}{18} \approx 1.056x - 0.389$

**误区一：把 $S_{xx} = 0$ 说成“回归直线不存在”。**　当所有 $x_i = x_0$ 时，

$$Q(a, b) = \sum_{i=1}^{n} [y_i - (a + bx_0)]^2 .$$

令 $c = a + bx_0$，则最优预测值为 $c = \bar{y}$；全部最优解恰为

$$a + bx_0 = \bar{y}, \qquad a = \bar{y} - bx_0.$$

也就是说，任意选择 $b$，再相应取 $a$，都会得到相同的最小残差平方和。数据只确定直线经过 $(x_0, \bar{y})$，却无法确定它穿过这里时该倾斜多少；正确结论是**斜率无法唯一估计**，而不是“回归直线不存在”。

**误区二：把最小二乘解释成最短垂距，或把两种回归互相倒过来。**　已知 $x$ 预测 $y$ 时，惩罚上下猜错；已知 $y$ 预测 $x$ 时，惩罚左右猜错。这是两个不同的问题，不能把一个公式直接倒过来。只有所有数据点都恰好落在同一条直线上时，两种回归才表示同一条几何直线。

图右的数据为 $(1,1), (2,2), (3,2), (4,4)$，中心为 $(2.5, 2.25)$。$y$ 对 $x$ 的回归为 $\hat{y} = 0.9x$；反向模型则是 $\hat{x} = \frac{18}{19}y + \frac{7}{19} \approx 0.947y + 0.368$。后者若要画在横轴为 $x$、纵轴为 $y$ 的普通坐标图中，必须等价改写为 $y = \frac{19}{18}x - \frac{7}{18} \approx 1.056x - 0.389$。这个改写只为画出同一条几何直线，**不能**把它当成“由 $x$ 预测 $y$”的公式。

**误区三：以为中心点检查能验证整条直线。**　代入 $(\bar{x}, \bar{y})$ 只能检查截距是否按 $\hat{a} = \bar{y} - \hat{b}\bar{x}$ 计算，不能单独验证斜率；因为任取一个错误斜率 $b$，再令 $a = \bar{y} - b\bar{x}$，直线仍会过中心。若需完整验算，可检查 $\sum e_i \approx 0$、$\sum x_i e_i \approx 0$（小数四舍五入时为近似）。



© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料

关注公众号 ok-shuxue，免费领取更多资料



## 结论小结

**一句话核心** 在 $x$ 有变化且散点趋势大致线性时，选取使纵向残差平方和最小的直线。

**速查公式**

$$\hat{b}=\frac{S_{xy}}{S_{xx}},\quad S_{xy}=\sum(x_i-\bar{x})(y_i-\bar{y}),\quad S_{xx}=\sum(x_i-\bar{x})^2,\quad \hat{a}=\bar{y}-\hat{b}\bar{x}.$$

**判断流程** 先确认 $x_i$ 不全相同（即 $S_{xx}>0$）；再求 $\bar{x},\bar{y},S_{xy},S_{xx}$；接着求 $\hat{b},\hat{a}$；最后做中心点检查截距，必要时检查 $\sum e_i\approx 0$。

**最后检查**

- 残差是否写成 $y_i-\hat{y}_i$，而非点到直线的最短距离？
- 分母是否是 $x$ 的离差平方和，并且严格大于 0？
- $S_{xy}$ 的符号是否与散点总体升降趋势一致？这只是粗略合理性检查，不是严格证明。
- 是否把样本中心检查只用于截距，而没有误称它能单独验证斜率？
- 预测 $x$ 是否在样本范围内；若在范围外，应说明属于外推？
- 是否还观察了散点的明显弯曲、分组或异常点？能算出回归线不代表线性模型一定合适。



© Math & Code Lab | 公众号：ok-shuxue | 内部教研资料