

卡方独立性检验

二级结论

条件

条件 1（期望频数要求）：

每个单元格的期望频数 $E_{ij} \geq 5$ ，或者至少 80% 的单元格期望频数 ≥ 5 。

条件 2（样本独立性）：

样本观测之间相互独立。

结论

结论一（卡方统计量定义）：

直观描述： 构造标准化偏离平方和，衡量观测与期望的总体偏离。

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

其中 $E_{ij} = \frac{R_i C_j}{n}$, $R_i = \sum_{j=1}^c O_{ij}$ 为第 i 行合计, $C_j = \sum_{i=1}^r O_{ij}$ 为第 j 列合计, $n = \sum_{i=1}^r R_i$ 为总频数。在独立性原假设 H_0 下, $\chi^2 \xrightarrow{\text{近似}} \chi^2(k)$, $k = (r-1)(c-1)$ 。对显著性水平 α , 若 $\chi^2 \geq \chi_{\alpha}^2(k)$, 则拒绝 H_0 , 认为两变量有关联; 否则保留 H_0 。

常见变形（等价计算公式）：

直观描述： 将平方展开后利用边际合计化简，便于手算。

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{O_{ij}^2}{E_{ij}} - n.$$

理解说明

一句话直觉

卡方统计量将每个单元格的观测频数与期望频数的差异进行平方并除以期望，再求和，整体偏差越大，越倾向于认为两变量有关联。

核心拆解

要点一（偏差平方标准化）：

每个单元格的贡献 $(O_{ij} - E_{ij})^2 / E_{ij}$ 既考虑绝对偏差，又用期望频数标准化，使不同量纲的单元格可以相加。

要点二（自由度决定临界值）：

自由度 $k = (r - 1)(c - 1)$ 反映独立条件下可自由变化的单元格数目，卡方分布的形状随 k 变化，临界值 $\chi^2_{\alpha}(k)$ 据此确定。

几何本质（标准化距离平方）

将每个单元格的标准化残差 $\frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}$ 视为一个坐标分量，则 χ^2 正是这些分量构成的向量的长度平方（即欧氏距离平方）。

代数意义（加权平方和）

$\chi^2 = \sum \frac{(O - E)^2}{E}$ 是偏差平方以 $1/E$ 为权的加权和。期望频数越小的单元格，权重越大，使得低频单元格的偏差对统计量更敏感。

考点价值（常见题型）

- **考法一（计算与判断）**：给出列联表，要求计算 χ^2 并与临界值比较，判断两变量是否独立。
- **考法二（条件检查）**：判断是否满足期望频数条件，若不满足需合并单元格或调整。

顿悟点

期望频数 E_{ij} 必须由行列合计计算，不能直接取整；近似条件必须提前验证，否则结论不可靠。

使用场景（典型应用）

- **场景一（列联表检验）**：已获得两个分类变量的交叉计数，检验是否独立。
- **场景二（问卷调查分析）**：分析两个问题之间是否存在关联，如性别与购买意愿。

证明

思路提示 卡方统计量的构造思想是利用标准化残差的平方和来量化整体偏离。在独立性假设下，当样本量足够大时，该统计量近似服从卡方分布，自由度由列联表维度决定。

正式推导

步骤一（期望频数计算）：

在独立性假设下，单元格 (i, j) 的期望频数为

$$E_{ij} = \frac{R_i C_j}{n},$$

其中 $R_i = \sum_{j=1}^c O_{ij}$, $C_j = \sum_{i=1}^r O_{ij}$, $n = \sum_{i=1}^r R_i$ 。

理由：如果两个变量独立，则行变量第 i 类的概率与列变量第 j 类的概率的估计值之积乘以总频数即为期望频数。

步骤二（标准化残差）：

定义标准化残差

$$z_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}.$$

理由：减去期望后除以标准差，使得不同量纲的单元格具有可比性。

步骤三（卡方统计量）：

卡方统计量为所有标准化残差的平方和：

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c z_{ij}^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

理由：平方和消除了正负抵消，反映累计偏离大小。

步骤四（近似与自由度）：

在 H_0 和期望频数条件满足下，每个 z_{ij} 近似服从标准正态分布，但由于行列合计固定，实际独立变化的单元格数为

$$(r-1)(c-1).$$

因此统计量近似服从 $\chi^2((r-1)(c-1))$ 。

理由：受约束的标准正态变量平方和服从卡方分布，自由度等于独立变量个数。

步骤五（假设检验决策）：

给定显著性水平 α ，查卡方分布临界值 $\chi_\alpha^2(k)$ 。若 $\chi^2 \geq \chi_\alpha^2(k)$ ，则拒绝 H_0 ，认为两变量有关联；否则不能拒绝 H_0 。

理由：小概率事件在一次试验中几乎不发生。若统计量落在拒绝域，说明观测到的偏离在 H_0 下是不寻常的，故怀疑 H_0 不成立。

结论回扣 卡方统计量是独立性检验的核心工具，通过比较观测与期望的标准化偏离平方和，在近似卡方分布的支持下做出统计推断。

典型例题

例 1（基础）

题目：为研究吸烟与肺癌是否有关联，调查 200 人得下表 ($\alpha = 0.05$):

	肺癌	无肺癌	合计
吸烟	30	70	100
不吸烟	10	90	100
合计	40	160	200

已知 $\chi_{0.05}^2(1) = 3.841$ 。

解题步骤：

第一步（计算期望）：

在独立性假设下，期望频数 $E_{ij} = R_i C_j / n$ 。得

$$E_{11} = 100 \times 40 / 200 = 20, \quad E_{12} = 100 \times 160 / 200 = 80,$$

$$E_{21} = 100 \times 40 / 200 = 20, \quad E_{22} = 100 \times 160 / 200 = 80.$$

理由：行列独立时，联合概率等于边际概率乘积。

第二步（检查条件）：

所有期望频数 20, 80, 20, 80 均 ≥ 5 ，满足使用条件。

理由：期望频数过小会导致卡方近似失效。

第三步（计算统计量）：

$$\begin{aligned}\chi^2 &= \frac{(30 - 20)^2}{20} + \frac{(70 - 80)^2}{80} + \frac{(10 - 20)^2}{20} + \frac{(90 - 80)^2}{80} \\ &= \frac{100}{20} + \frac{100}{80} + \frac{100}{20} + \frac{100}{80} \\ &= 5 + 1.25 + 5 + 1.25 \\ &= 12.5.\end{aligned}$$

理由：卡方统计量为所有单元格标准化偏差平方之和。

第四步（假设检验决策）：

比较临界值 $\chi_{0.05}^2(1) = 3.841$ 。因为 $12.5 > 3.841$ ，所以拒绝 H_0 ，认为吸烟与肺癌有关联。

理由：小概率事件发生，拒绝原假设。

关键结论： $\chi^2 = 12.5 > 3.841$ ，拒绝独立性假设，两变量存在关联。

例 2（稍变形）

题目：为调查性别与收入水平是否独立，随机抽取 100 人，数据如下 ($\alpha = 0.05$):

	低收入	中收入	高收入	合计
男	15	10	25	50
女	15	20	15	50
合计	30	30	40	100

已知 $\chi_{0.05}^2(2) = 5.991$ 。

解题步骤：

第一步（计算期望）：

期望频数按 $E_{ij} = R_i C_j / n$ 计算。得：

$$E_{11} = 50 \times 30/100 = 15, E_{12} = 50 \times 30/100 = 15, E_{13} = 50 \times 40/100 = 20,$$

$$E_{21} = 50 \times 30/100 = 15, E_{22} = 50 \times 30/100 = 15, E_{23} = 50 \times 40/100 = 20.$$

理由：独立性假设下的估计公式。

第二步（检查条件）：

所有期望频数均为 15 或 20，均 ≥ 5 ，条件满足。

理由：确保卡方近似有效。

第三步（计算统计量）：

$$\begin{aligned}\chi^2 &= \frac{(15-15)^2}{15} + \frac{(10-15)^2}{15} + \frac{(25-20)^2}{20} \\ &\quad + \frac{(15-15)^2}{15} + \frac{(20-15)^2}{15} + \frac{(15-20)^2}{20} \\ &= 0 + \frac{25}{15} + \frac{25}{20} + 0 + \frac{25}{15} + \frac{25}{20} \\ &= 1.6667 + 1.25 + 1.6667 + 1.25 \\ &= 5.8334.\end{aligned}$$

理由：各单元格贡献相加。

第四步（假设检验决策）：

$\chi^2 = 5.8334 < 5.991$ ，不在拒绝域，不能拒绝 H_0 。

理由：统计量不够大，无法认为存在显著关联。

关键结论： $\chi^2 = 5.8334 < 5.991$ ，不拒绝独立性假设，性别与收入无显著关联。

例 3（综合应用）

题目： 研究年级与食堂满意度关系，调查 40 名学生得下表 ($\alpha = 0.05$):

	满意	不满意	合计
高一	15	5	20
高二	10	5	15
高三	0	5	5
合计	25	15	40

已知 $\chi_{0.05}^2(2) = 5.991$, $\chi_{0.05}^2(1) = 3.841$ 。

解题步骤：

第一步（计算期望）：

$$E_{11} = 20 \times 25/40 = 12.5, E_{12} = 20 \times 15/40 = 7.5,$$

$$E_{21} = 15 \times 25/40 = 9.375, E_{22} = 15 \times 15/40 = 5.625,$$

$$E_{31} = 5 \times 25/40 = 3.125, E_{32} = 5 \times 15/40 = 1.875.$$

理由： 独立性假设下公式。

第二步（检查条件）：

只有 4 个单元格期望 ≥ 5 （比例 66.7%），低于 80%，不满足使用条件。需要处理。

理由： 期望频数过小可能导致检验不准确。

第三步（合并类别）：

将高二和高三合并为“高年级”，新表：

	满意	不满意	合计
高一	15	5	20
高年级	10	10	20
合计	25	15	40

新期望： $E_{11} = 12.5$, $E_{12} = 7.5$, $E_{21} = 12.5$, $E_{22} = 7.5$ ，均 ≥ 5 。

理由： 合并后保留主要结构，同时满足条件。

第四步（计算卡方）：

$$\begin{aligned}\chi^2 &= \frac{(15 - 12.5)^2}{12.5} + \frac{(5 - 7.5)^2}{7.5} + \frac{(10 - 12.5)^2}{12.5} + \frac{(10 - 7.5)^2}{7.5} \\&= \frac{6.25}{12.5} + \frac{6.25}{7.5} + \frac{6.25}{12.5} + \frac{6.25}{7.5} \\&= 0.5 + 0.8333 + 0.5 + 0.8333 \\&= 2.6667.\end{aligned}$$

理由：卡方公式直接计算。

第五步（假设检验决策）：

自由度 $k = (2-1)(2-1) = 1$ ，临界值 $\chi_{0.05}^2(1) = 3.841$ 。 $\chi^2 = 2.6667 < 3.841$ ，不能拒绝 H_0 。

理由：统计量未达到显著水平，数据不足以推翻独立性假设。

关键结论： 合并后 $\chi^2 = 2.6667 < 3.841$ ，不拒绝独立性假设，年级与满意度无显著关联。

易错提醒**易错点一（期望频数计算）**

计算期望频数时直接用行合计或列合计代替，或忘记除以总频数。

正确理解（公式记忆）

期望频数必须为 $E_{ij} = R_i C_j / n$ ，即行合计乘列合计再除以总频数。

错因分析（混淆概念）

误以为期望频数就是行合计或列合计，忽略了联合概率的估计。

易错点二（自由度确定）

计算自由度时误写为 $rc - 1$ 或 $r + c - 2$ ，导致查临界值错误。

正确理解（自由含义）

独立变量单元格数为 $(r-1)(c-1)$ ，扣除行列合计约束后的自由度。

错因分析（线性约束）

不理解行列合计固定后实际可自由变化的单元格数，简单采用总单元格数减一。

易错点三（条件忽视）

未检验期望频数条件或样本独立性，直接计算卡方并下结论。

正确理解（必须验证）

使用条件：各单元格期望频数 ≥ 5 （或至少 80% 满足），且样本相互独立。

错因分析（条件缺失）

忽视前提导致卡方近似失效，结论可能不可靠。

结论小结**一句话核心**

卡方独立性检验通过比较观测与期望频数的标准化偏离平方和，借助卡方分布判断两分类变量是否独立。

使用条件

- 条件 1（期望频数足够）：**每个单元格期望频数 ≥ 5 ，或至少 80% 的单元格期望频数 ≥ 5 。
- 条件 2（样本独立性）：**不同个体的观测结果相互独立。

关键提醒

- 易错点（公式与条件）：**期望频数计算公式为 $E_{ij} = R_i C_j / n$ ；自由度 $k = (r - 1)(c - 1)$ ；必须提前验证条件。
- 检查项（计算与结论）：**计算 χ^2 后与临界值比较，在拒绝域中才拒绝 H_0 ，注意临界值与自由度对应。